

02-jj-eda-clientes

May 14, 2026

1 Proyecto 3 - EDA de clientes

1.1 Integrantes

- Daniel Fernando Salgado Santamaría
- Jairo Wladimir Jhayya Perlaza
- Luis Gabriel Salgado Santamaría
- Oscar Paul Naranjo Castro

Fecha: 2026-05-13

Notebook: 02-jj-eda-clientes.ipynb

1.2 Objetivo

Realizar el análisis exploratorio de clientes y su comportamiento a partir de las tablas: - customers - sessions - events - orders - order_items - products - reviews

Este notebook construye una primera visión del cliente integrando variables demográficas, actividad de navegación, compras y reseñas, para preparar la siguiente etapa de feature engineering y clustering.

Python ejecutándose desde:

g:\ProyectosPython\proyecto3\.venv\Scripts\python.exe

PROJECT_ROOT: G:\ProyectosPython\proyecto3\desarrollo3

RAW_DIR: G:\ProyectosPython\proyecto3\desarrollo3\data\raw

PROCESSED_DIR: G:\ProyectosPython\proyecto3\desarrollo3\data\processed

FIGURES_DIR: G:\ProyectosPython\proyecto3\desarrollo3\reports\figures

TABLES_DIR: G:\ProyectosPython\proyecto3\desarrollo3\reports\tables

1.3 Carga de datos

Se cargan nuevamente los archivos fuente desde `data/raw/` para que este notebook sea independiente, reproducible y reutilizable por cualquier integrante del equipo.

customers: (20000, 7)

sessions: (120000, 6)

events: (760958, 10)

orders: (33580, 10)

order_items: (59163, 5)

products: (1197, 6)

reviews: (10780, 6)

1.4 Conversión inicial de tipos

Se convierten fechas a `datetime` y algunas variables categóricas a `category` para mejorar análisis temporal, eficiencia en memoria y legibilidad del dataset.


Las transformaciones anteriores aseguran tipos consistentes para el análisis temporal y categórico, y sientan las bases para la construcción de métricas agregadas a nivel de cliente en la siguiente sección.

1.5 1. Exploración básica de clientes


Se analizan variables centrales de `customers`: - edad, - aceptación de marketing, - país, - evolución temporal del registro.


customer_id		name	email	country	age
signup_date	marketing_opt_in				
0	1	Jennifer Salinas	nicholas59@example.org	JP	71
2020-09-04	True				
1	2	Phillip Ramos	christinarubio@example.com	IN	26
2020-04-05	False				
2	3	Dawn Fowler	jessica03@example.org	BR	21
2023-08-31	True				
3	4	Mario Butler	paula27@example.org	FR	63
2022-06-30	True				
4	5	Amber Brown	kevin85@example.net	BR	19
2022-07-22	True				

	age
count	20,000.00
mean	46.49
std	16.77
min	18.00
25%	32.00
50%	46.50
75%	61.00
max	75.00




	marketing_opt_in	proportion	percentage
0	True	0.56	55.55
1	False	0.44	44.45





	signup_date	new_customers
0	2020-01-01	288
1	2020-02-01	261
2	2020-03-01	281
3	2020-04-01	255
4	2020-05-01	288



1.6 2. Construcción de métricas de comportamiento

Se generan métricas agregadas por cliente usando: - sesiones, - órdenes, - reseñas.

Estas métricas permiten crear una tabla consolidada para segmentación posterior.

customer_id	n_sessions
0	1
	5

1	2	3
2	3	5
3	4	9
4	5	9

	customer_id	n_orders	gross_revenue_usd	avg_order_value_usd
0	1	2	115.39	57.69
1	2	2	68.52	34.26
2	3	1	66.72	66.72
3	4	2	279.86	139.93
4	5	3	271.29	90.43

	customer_id	n_reviews
0	1	1
1	5	4
2	6	3
3	10	3
4	15	1

	customer_id	country	age	signup_date	marketing_opt_in	n_sessions	n_orders
gross_revenue_usd							
0	1	JP	71	2020-09-04	True	5.00	2.00
115.39			57.69	1.00			
1	2	IN	26	2020-04-05	False	3.00	2.00
68.52			34.26	0.00			
2	3	BR	21	2023-08-31	True	5.00	1.00
66.72			66.72	0.00			
3	4	FR	63	2022-06-30	True	9.00	2.00
279.86			139.93	0.00			
4	5	BR	19	2022-07-22	True	9.00	3.00
271.29			90.43	4.00			


	age	n_sessions	n_orders	gross_revenue_usd	avg_order_value_usd
n_reviews					
count	20,000.00	20,000.00	20,000.00	20,000.00	20,000.00
20,000.00					
mean	46.49	6.00	1.68	224.66	109.14
0.54					
std	16.77	2.47	1.29	262.27	122.42
1.11					
min	18.00	0.00	0.00	0.00	0.00
0.00					
25%	32.00	4.00	1.00	32.16	27.14
0.00					
50%	46.50	6.00	2.00	145.39	82.58
0.00					
75%	61.00	8.00	2.00	322.40	151.05
1.00					
max	75.00	17.00	9.00	3,026.42	2,680.64


10.00

Las métricas anteriores resumen el comportamiento de cada cliente en términos de edad, frecuencia de interacción con el sitio (`n_sessions`), volumen de compras (`n_orders` y `gross_revenue_usd`), gasto promedio por orden (`avg_order_value_usd`) y nivel de participación en reseñas (`n_reviews`). Esta tabla consolidada será el insumo principal para la etapa de clustering en el notebook `03-jj-clustering-clientes.ipynb`.

1.7 3. Distribución de actividad y valor del cliente

Se exploran: - número de sesiones, - número de órdenes, - ingreso total, - valor promedio por orden.






1.8 4. Relaciones entre variables numéricas

Se analiza la correlación entre métricas numéricas del cliente para detectar asociaciones iniciales útiles para la siguiente etapa de segmentación.

	age	n_sessions	n_orders	gross_revenue_usd
avg_order_value_usd	n_reviews			
age	1.00	0.01	0.01	0.00
0.00	0.01			
n_sessions	0.01	1.00	0.53	0.35
0.14	0.20			
n_orders	0.01	0.53	1.00	0.66
0.26	0.38			
gross_revenue_usd	0.00	0.35	0.66	1.00
0.77	0.33			
avg_order_value_usd	0.00	0.14	0.26	0.77
1.00	0.17			
n_reviews	0.01	0.20	0.38	0.33
0.17	1.00			



1.9 5. Guardado de resultados

Se guardan: - la tabla consolidada `customer_features.csv`, - un resumen estadístico de variables numéricas, - y todas las figuras generadas en alta resolución.

Tabla guardada en:

G:\ProyectosPython\proyecto3\desarrollo3\data\processed\customer_features.csv

Resumen estadístico guardado en: G:\ProyectosPython\proyecto3\desarrollo3\reports\tables\customer_features_summary.csv

1.10 Interpretación final del EDA de clientes

El análisis exploratorio permitió integrar en una sola tabla (`customer_features`) la información demográfica básica del cliente junto con su comportamiento de navegación, compra y generación de reseñas. La edad de los clientes se distribuye de forma relativamente uniforme entre 18 y 75 años, con una mediana de 46 años, mientras que la actividad en la plataforma es heterogénea: la mayoría

de clientes registra entre 4 y 8 sesiones y entre 1 y 2 órdenes, pero existe una cola de usuarios con volúmenes de compra y gasto significativamente mayores.

Las métricas económicas muestran que tanto el ingreso total por cliente (**gross_revenue_usd**) como el ticket promedio (**avg_order_value_usd**) presentan una variabilidad elevada —con desviaciones estándar comparables a sus respectivas medias— lo que sugiere la presencia de segmentos con valor económico muy distinto. De forma complementaria, el número de reseñas (**n_reviews**) es bajo para la mayoría de clientes, con mediana en cero, indicando que la participación activa en evaluaciones es un comportamiento poco frecuente y, por tanto, potencialmente diferenciador entre grupos.

La estructura observada avala la decisión de utilizar estas seis variables numéricas como base para la segmentación posterior. La tabla **customer_features** resume de manera compacta los perfiles de uso, valor y engagement de los clientes, proporcionando un punto de partida sólido para aplicar K-Means y derivar segmentos accionables.

1.11 Resultado de esta etapa

En este notebook se realizó el análisis exploratorio de clientes y se consolidó una tabla **customer_features.csv** que integra: - datos demográficos, - nivel de actividad, - comportamiento de compra, - y reseñas.

Además, se generaron figuras de alta calidad y tablas resumen reutilizables para el informe final y para la siguiente fase de clustering.