

03-jj-clustering-clientes

May 14, 2026

1 Proyecto 3 - Clustering de clientes con K-Means

1.1 Integrantes

- Daniel Fernando Salgado Santamaría
- Jairo Wladimir Jhayya Perlaza
- Luis Gabriel Salgado Santamaría
- Oscar Paul Naranjo Castro

Fecha: 2026-05-13

Notebook: 03-jj-clustering-clientes.ipynb

1.2 Objetivo

Aplicar clustering no supervisado sobre la tabla `customer_features.csv` para identificar segmentos de clientes con comportamientos similares.

Se evaluará el número adecuado de clusters mediante: - método del codo, - silhouette score, - análisis descriptivo de los segmentos generados.

PROJECT_ROOT: G:\ProyectosPython\proyecto3\desarrollo3

PROCESSED_DIR: G:\ProyectosPython\proyecto3\desarrollo3\data\processed

CLUSTER_FIG_DIR:

G:\ProyectosPython\proyecto3\desarrollo3\reports\figures\clustering_clientes

1.3 Carga de datos

Se carga la tabla consolidada de clientes generada en el notebook anterior.

(20000, 10)

customer_id	country	age	signup_date	marketing_opt_in	n_sessions	n_orders	
gross_revenue_usd	avg_order_value_usd	n_reviews					
0	1	JP	71	2020-09-04	True	5.00	2.00
115.39		57.69	1.00				
1	2	IN	26	2020-04-05	False	3.00	2.00
68.52		34.26	0.00				
2	3	BR	21	2023-08-31	True	5.00	1.00
66.72		66.72	0.00				
3	4	FR	63	2022-06-30	True	9.00	2.00
279.86		139.93	0.00				

4	5	BR	19	2022-07-22	True	9.00	3.00
271.29			90.43	4.00			

```
<class 'pandas.DataFrame'>
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   customer_id           20000 non-null  int64
1   country               20000 non-null  str
2   age                   20000 non-null  int64
3   signup_date           20000 non-null  str
4   marketing_opt_in      20000 non-null  bool
5   n_sessions            20000 non-null  float64
6   n_orders              20000 non-null  float64
7   gross_revenue_usd     20000 non-null  float64
8   avg_order_value_usd   20000 non-null  float64
9   n_reviews             20000 non-null  float64
dtypes: bool(1), float64(5), int64(2), str(2)
memory usage: 1.4 MB
```

1.4 Selección de variables para clustering

Se seleccionan variables numéricas asociadas al comportamiento del cliente para evitar mezclar directamente variables categóricas en K-Means.

	age	n_sessions	n_orders	gross_revenue_usd	avg_order_value_usd	n_reviews
0	71	5.00	2.00	115.39	57.69	1.00
1	26	3.00	2.00	68.52	34.26	0.00
2	21	5.00	1.00	66.72	66.72	0.00
3	63	9.00	2.00	279.86	139.93	0.00
4	19	9.00	3.00	271.29	90.43	4.00

```
age                0
n_sessions         0
n_orders           0
gross_revenue_usd  0
avg_order_value_usd 0
n_reviews          0
dtype: int64
```

Shape escalado: (20000, 6)


1.5 Evaluación del número de clusters

Se prueba una secuencia de valores de k para analizar: - inercia (método del codo), - silhouette score.


	k	inertia	silhouette_score
0	2	86,894.49	0.30

1	3	76,032.62	0.26
2	4	66,362.27	0.23
3	5	57,772.15	0.22
4	6	53,163.20	0.20
5	7	49,236.69	0.19
6	8	46,345.51	0.20
7	9	43,706.24	0.20
8	10	41,677.03	0.20

La tabla anterior confirma que el mayor silhouette score se obtiene con ($k=2$) (0.30), mientras que para ($k \geq 3$) la calidad de separación entre clusters disminuye de forma consistente. Por ello, se adopta ($k=2$) como número óptimo de segmentos para el análisis de esta sección.



El método del codo muestra que la reducción de inercia es más pronunciada al pasar de ($k=2$) a ($k=3$), y se desacelera progresivamente para valores superiores. Esto indica que ($k=2$) representa el punto de mayor ganancia de compacidad relativa antes de que la mejora incremental se vuelva marginal.




1.6 Selección del modelo final

Con base en los resultados del codo y silhouette, se elige un valor final de k para construir la segmentación.

Mejor número de clusters según silhouette score: 2

	customer_id	cluster
0	1	1
1	2	1
2	3	1
3	4	0
4	5	0

	cluster	customers_count	percentage
0	0	7041	35.20
1	1	12959	64.80




1.7 Perfilamiento de clusters

Se calcula el promedio de las variables numéricas en cada cluster para interpretar el comportamiento característico de cada segmento.

	cluster	age	n_sessions	n_orders	gross_revenue_usd	avg_order_value_usd
n_reviews						
0	0	46.97	7.65	2.86	476.67	193.40
1.21						
1	1	46.23	5.10	1.04	87.74	63.35
0.18						

Tabla guardada en: G:\ProyectosPython\proyecto3\desarrollo3\reports\tables\cluster_profile_kmeans.csv

	cluster	metric	mean_value
0	0	age	46.97
1	1	age	46.23
2	0	n_sessions	7.65
3	1	n_sessions	5.10
4	0	n_orders	2.86




cluster	customers_count	percentage	age	n_sessions	n_orders	
gross_revenue_usd	avg_order_value_usd	n_reviews				
0	0	7041	35.20	46.97	7.65	2.86
476.67		193.40	1.21			
1	1	12959	64.80	46.23	5.10	1.04
87.74		63.35	0.18			

Resumen final guardado en: G:\ProyectosPython\proyecto3\desarrollo3\data\processed\customer_clusters_kmeans.csv

1.8 Visualización bidimensional de clusters

Se proyecta el comportamiento de los clientes en variables de negocio interpretables para observar la separación entre clusters.



1.9 Resultado de esta etapa

En este notebook se aplicó K-Means sobre la tabla `customer_features.csv`, se seleccionó un número de clusters con apoyo del método del codo y silhouette score, y se generaron tablas y gráficos para describir los segmentos de clientes identificados.

1.10 6. Visualización de clusters con PCA


Se aplica Análisis de Componentes Principales (PCA) sobre las variables estandarizadas usadas en K-Means para: - reducir la dimensionalidad a 2 componentes principales, - visualizar los clusters en un espacio 2D, - analizar cuánta varianza explican los primeros componentes.

1.10.1 Análisis de Componentes Principales (PCA)


A continuación se aplica PCA sobre las variables numéricas de clustering para reducir la dimensionalidad y visualizar la estructura de los segmentos en un plano bidimensional. Este análisis complementa la segmentación obtenida con K-Means al permitir identificar qué variables explican la mayor proporción de varianza y evaluar visualmente la separación entre clusters.

Shape PCA: (20000, 2)

```
array([0.43223663, 0.1753235 ])
```



	component	explained_variance_ratio	explained_variance_pct
0	1	0.43	43.22
1	2	0.18	17.53




1.11 7. Interpretación de componentes principales

Se analizan los loadings de PCA para identificar qué variables originales contribuyen con mayor peso a los dos primeros componentes principales.

	feature	PC1	PC2
0	age	0.01	-0.19
1	n_sessions	0.37	-0.52
2	n_orders	0.51	-0.31
3	gross_revenue_usd	0.56	0.31
4	avg_order_value_usd	0.42	0.65
5	n_reviews	0.33	-0.29

	feature	component	loading	abs_loading
0	age	PC1	0.01	0.01
1	n_sessions	PC1	0.37	0.37
2	n_orders	PC1	0.51	0.51
3	gross_revenue_usd	PC1	0.56	0.56
4	avg_order_value_usd	PC1	0.42	0.42



Variables más influyentes en PC1

	feature	PC1	abs_PC1
3	gross_revenue_usd	0.56	0.56
2	n_orders	0.51	0.51
4	avg_order_value_usd	0.42	0.42
1	n_sessions	0.37	0.37
5	n_reviews	0.33	0.33
0	age	0.01	0.01

Variables más influyentes en PC2

	feature	PC2	abs_PC2
4	avg_order_value_usd	0.65	0.65
1	n_sessions	-0.52	0.52
2	n_orders	-0.31	0.31
3	gross_revenue_usd	0.31	0.31
5	n_reviews	-0.29	0.29
0	age	-0.19	0.19

1.12 Interpretación final de los clusters K-Means

La evaluación del número de clusters mediante inercia y silhouette score indica que ($k=2$) ofrece el mejor compromiso entre compacidad interna y separación entre grupos. El silhouette score alcanza su valor máximo en ($k=2$) (0.30) y disminuye de forma progresiva para valores superiores, confirmando que una solución de dos segmentos es la más adecuada para este conjunto de datos.

El perfil medio de cada cluster revela diferencias claras en actividad e ingreso:

- **Cluster 0 — Clientes de alto valor** (35 % de la base): mayor número de sesiones (media 7.65), más órdenes por cliente (media 2.86), ingreso total notablemente superior (media USD 476.67) y ticket promedio elevado (media USD 193.40). También registra un número mayor de reseñas (media 1.21), lo que refleja un engagement más activo con la plataforma.

- **Cluster 1 — Clientes de menor valor** (65 % de la base): menor frecuencia de sesiones (media 5.10), pocas órdenes (media 1.04), ingreso total reducido (media USD 87.74) y ticket promedio bajo (media USD 63.35). Las reseñas son casi inexistentes (media 0.18), indicando un nivel de interacción limitado.

Desde una perspectiva de negocio, esta segmentación permite diferenciar de forma directa clientes de alto y bajo valor, facilitando estrategias diferenciadas de priorización comercial, asignación de recursos de marketing y diseño de programas de retención o activación según el perfil de cada grupo.

1.13 Interpretación final de PCA y visualización de segmentos

Los dos primeros componentes principales explican aproximadamente el 60 % de la varianza total (PC1: 43.22 %, PC2: 17.53 %), lo que justifica la representación bidimensional como una aproximación razonable de la estructura multivariada de los datos.

Los loadings de PC1 muestran que las variables de mayor contribución son **gross_revenue_usd** (0.56), **n_orders** (0.51) y **avg_order_value_usd** (0.42), por lo que este componente puede interpretarse como una **dimensión general de valor económico y volumen de compras**. PC2, en cambio, recibe su mayor aportación de **avg_order_value_usd** (0.65) con signo positivo y de **n_sessions** (−0.52) con signo negativo, lo que sugiere una **dimensión de contraste entre gasto por transacción y frecuencia de visitas**: clientes con ticket alto pero pocas sesiones se ubican en valores positivos de PC2, mientras que clientes muy frecuentes pero con gasto por orden más bajo tienden a valores negativos.

La proyección de los clusters en el plano PCA muestra que el cluster de alto valor se concentra en la zona de valores elevados de PC1, mientras que el cluster de menor valor se agrupa en la zona de valores bajos. Esta separación visual confirma que las diferencias capturadas por K-Means son coherentes con la estructura real de los datos y no un artefacto del algoritmo. En conjunto, el PCA refuerza la validez de la segmentación obtenida y ofrece una representación intuitiva de la distancia entre perfiles de cliente.